嵌入式系統軟體設計與實作 實驗報告十三

資工三 許耘熙 411410054

實驗名稱:

從原始碼建置 TVM 並在嵌入式裝置上部署深度學習模型

實驗目的:

從原始碼編譯並安裝 TVM,在樹梅派上編譯並部署 TVM Runtime,設置 RPC 伺服器以支援遠端推論。透過範例程式,實作在資源受限裝置上使用 TVM RPC 執行 ResNet-18 模型推論。評估不同最佳化等級(opt_level)對編譯時間、執行時間與記憶體使用的影響,以及遠端與本地執行效能差異。

實驗步驟:

```
1. 在本機設置相關環境以及安裝套件並編譯 TVM
sudo apt-get install -y python3 python3-dev python3-setuptools \
gcc git libtinfo-dev zlib1g-dev build-essential cmake libedit-dev \
libxml2-dev llvm-dev llvm
wget https://dlcdn.apache.org/tvm/tvm-v0.18.0/apache-tvm-src-
v0.18.0.tar.gz
tar zxvf apache-tvm-src-v0.18.0.tar.gz
mv apache-tvm-src-v0.18.0 tvm
cd tvm
rm -rf build && mkdir build && cd build
cp ../cmake/config.cmake .
echo "set(USE_LLVM ON)" >> config.cmake
echo "set(HIDE PRIVATE SYMBOLS ON)" >> config.cmake
echo "set(USE_CUDA OFF)" >> config.cmake
echo "set(USE_METAL OFF)" >> config.cmake
echo "set(USE_OPENCL OFF)" >> config.cmake
echo "set(USE_CUBLAS OFF)" >> config.cmake
echo "set(USE_CUDNN OFF)" >> config.cmake
echo "set(USE_CUTLASS OFF)" >> config.cmake
echo "set(USE_GRAPH_EXECUTOR ON)" >> config.cmake
echo "set(USE_PROFILER ON)" >> config.cmake
cmake .. -G Ninja
```

```
ninja
echo "export PYTHONPATH=$TVM_HOME/python:$PYTHONPATH" >> ~/.bashrc
source ~/.bashrc
sudo -s
apt install python3-pip
python3 -m venv ./lab13
source ./lab13/bin/activate
pip install numpy decorator attrs typing-extensions psutil scipy ackslash
packaging Pillow torchvision tornado
python -c "import_tvm;print(tvm. version )"
2. 在樹莓派上設置相關環境以及安裝套件並編譯 TVM
ssh -X yunhsihsu@172.16.1.53
wget https://dlcdn.apache.org/tvm/tvm-v0.18.0/apache-tvm-src-
v0.18.0.tar.gz
tar zxvf apache-tvm-src-v0.18.0.tar.gz
mv apache-tvm-src-v0.18.0 tvm
cd tvm
rm -rf build && mkdir build && cd build
cp ../cmake/config.cmake .
sudo fallocate -l 4G /swapfile
sudo chmod 600 /swapfile
sudo /mkswap /swapfile
sudo swapon /swapfile
echo "set(USE GRAPH EXECUTOR ON)" >> config.cmake
cmake .. -G Ninja
ninja runtime -v -j3
echo "export TVM_HOME=~/tvm" >> ~/.bashrcecho
echo "export PYTHONPATH=$TVM HOME/python:$PYTHONPATH" >> ~/.bashrc
source ~/.bashrc
python3 -m venv ./env
source ./env/bin/activate
pip install numpy decorator attrs typing-extensions psutil tornado\
packaging torchvision cloudpickle
cd ..
python -m tvm.exec.rpc server --host 0.0.0.0 --port=9090
```

3. 在本機上執行程式碼

pip install pytest python test.py

問題與討論:

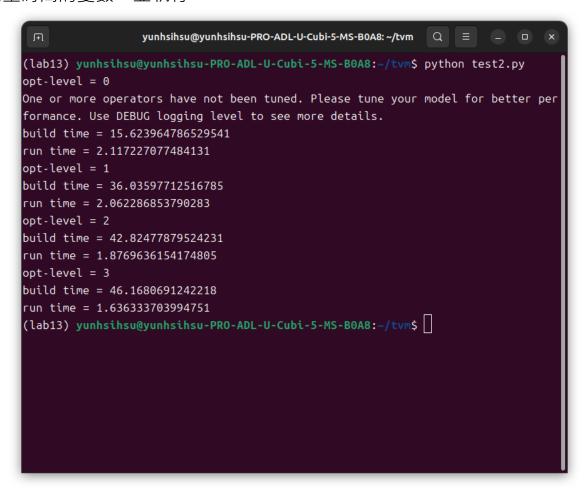
1. 請截圖成功執行程式的結果。

```
yunhsihsu@raspberrypi:~ $ python -m tvm.exec.rpc_server --host 0.0.0.0 --p
ort=9090
INFO:root:If you are running ROCM/Metal, fork will cause compiler internal error
. Try to launch with arg ```-no-fork```
2025-06-09 22:10:06.393 INFO bind to 0.0.0:09090
2025-06-09 22:10:15.764 INFO connected from ('172.16.1.72', 54196)
2025-06-09 22:10:768 INFO start serving at /tmp/tmprpdfexpo
2025-06-09 22:12:56.080 INFO load_module /tmp/tmprpdfexpo/lib.tar
2025-06-09 22:13:00.677 INFO finish serving ('172.16.1.72', 54196)
```

執行 test.py

2. 比較不同 TVM opt_level 的效能 (opt_level=0,1,2,3),使用 Python 所提供的 time.time 分別計算 relay.build(mod,target,params) 的編譯時間與module.run()的執行時間。請嘗試說明每個 opt_leve 對模型進行了哪些優化,並觀察 build 時間與 run 時間的差異。

加入測量時間的變數,並執行



opt_level Ø:不進行任何優化,直接把 Relay IR 轉為原始程式碼,僅作必要的型別與形狀檢查。

opt level 1:基本優化,常數折疊與死代碼消除

opt_level 2:中等優化,算子融合與資料布局轉換

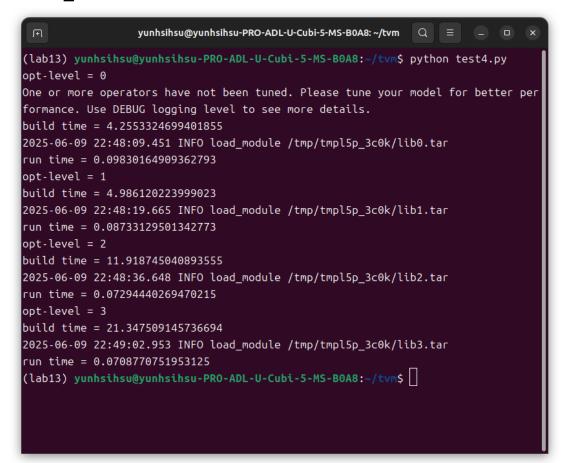
opt_level 3:高度優化,向量化、迴圈展開、SIMD使用等,並做線程排程與記憶體預取。

優化越多,編譯時間越長,執行時間越短

3. 比較 TVM opt_level 為 0 與 3 時,在不同優化下的記憶體使用情況。請透過下列程式碼觀察記憶體變化,並簡要分析 build 階段與 run 階段的記憶體使用差異。加入測量空間的變數,並執行

因為 opt_level 3 的優化較多,因此也會使用較多空間。

4. 修改 local_demo 變數為 True,在本地執行推論,



5. 實驗心得:

在本次實驗中,我遇到最大的困難是在樹莓派上面操作時,常常會當機,造成很多時候都在重複操作相同內容,光是樹莓派的編譯致少花費了 5 天,後續的操作就不會太困難了。這次的實驗我了解了 TVM 的建置流程與可客製化的最佳化選項,並實際操作了跨平台部署與遠端推論機制,充分的加深了對嵌入式裝置上深度學習部署挑戰的認識。